

《大模型调优与部署技术》课程教学大纲

课程代码：SK3020

学 分：2

学 时：36（理论学时：18，实践学时：18）

先修课程：无

适用专业：数据科学与大数据技术（专升本）专业、数据科学与大数据技术专业、人工智能专业

课程性质：必修

开课单位：软件与人工智能学院

一、课程的性质和地位

本课程是数据科学与大数据技术（专升本）专业的必修课，是数据科学与大数据技术（专升本）专业的专业必修课。本课程也是数据科学与大数据技术专业、人工智能专业的选修课，是数据科学与大数据技术专业的专业任选课，同时也是人工智能专业的专业限选课。此外，本课程也可作为其他专业的选修课。

二、课程目标

目标 1：学生能够在给定开源大语言模型调优与部署典型应用场景的条件下，说明本地推理、提示词工程、检索增强生成、数据处理、数据扩充、SFT 微调、LoRA 微调、强化学习、模型评估与量化部署等核心概念、基本原理和技术流程，能够解释各环节在大模型训练优化、应用开发与部署中的作用及相互关系。

目标 2：学生能够在给定开源模型、数据集、开发环境和实验任务的条件下，完成大语言模型本地调用、提示词设计、知识库构建、微调训练、效果评估和量化部署等基础实践任务，能够实现过程规范、结果可运行、指标可记录的大模型应用开发与调优部署原型。

目标 3：学生能够在遵守人工智能伦理、数据安全和工程规范的条件下，分析大模型调优与部署过程中的数据质量、模型效果、资源消耗和应用风险问题，形成负责任的技术应用意识、工程实践意识、创新探索精神和持续学习前沿技术的能力。

三、课程教学内容、要求及学时分配

（一）教学内容与学时分配

教学内容	推荐学时	讲授学时	实验学时	支撑课程目标
第1章 开源大模型运行原理与量化部署	6	3	3	目标 1、2、3
第2章 提示词工程与 RAG 应用开发	8	4	4	目标 1、2、3
第3章 大模型监督微调与训练数据构建	8	4	4	目标 1、2、3
第4章 继续预训练与偏好对齐	4	2	2	目标 1、2、3
第5章 大模型评估与效果分析	2	1	1	目标 1、2、3
第6章 大模型推理服务与部署	4	2	2	目标 1、2、3
第7章 视觉大模型应用与微调	4	2	2	目标 1、2、3
总计	36	18	18	

（二）教学内容与要求

第1章 开源大模型运行原理与量化部署

学习目标：

（1）知识目标：说明开源大模型的文件组成、本地推理调用链、Tokenizer 与 Chat Template 的作用，理解自回归生成、数值精度与低比特量化的基本原理。

（2）能力目标：能够配置本地推理环境，下载并加载开源模型，使用 pipeline 及底层接口完成推理；能够比较 FP32、FP16、BF16、8bit 与 4bit 方案的显存占用和输出效果。

（3）素质目标：形成自主可控、规范使用开源模型和节约算力资源的意识，能够基于运行数据客观分析部署方案的适用条件与局限。

课程思政安排：结合国产开源大模型生态和量化部署实践，引导学生认识自主创新与开源协作的价值，在模型下载、许可证遵循和算力使用中坚持规范、安全与绿色计算。

学习内容：

- （1）开源大模型、本地推理与量化部署的概念及应用场景。
- （2）模型权重、配置、分词器和生成配置文件的组织与作用。
- （3）Anaconda、VSCode、CUDA、PyTorch、Transformers 环境配置及模型下载管理。
- （4）Tokenizer、Chat Template 与自回归生成流程及主要生成参数。
- （5）pipeline 与 AutoTokenizer、AutoModelForCausalLM 两类推理方式。
- （6）FP32、FP16、BF16、8bit、4bit 方案及 bitsandbytes 关键配置。
- （7）不同精度方案的显存、稳定性和输出质量对比。

重点和难点：开源模型文件结构及 Tokenizer 与 Chat Template；本地推理调用链和精度配置；模型量化方法及显存、速度、输出质量的权衡。

学习资源：

- (1) 课件：对应第 1—3 节的内容。
- (2) 实验材料：对应实验 1—3 的相关材料。
- (3) 教材：对应开源模型推理、量化和本地部署的相关内容。
- (4) 线上资源：Transformers 官方文档 (<https://huggingface.co/docs/transformers/index>)；Hugging Face Hub 下载指南 (https://huggingface.co/docs/huggingface_hub/guides/download)；bitsandbytes 官方文档 (<https://huggingface.co/docs/bitsandbytes/index>)。
- (5) 在线课程：《大模型调优与部署技术》在线课程（课程号：YKmxR3），智慧树平台 (<https://www.zhihuishu.com/>)。

作业要求：

完成实验 1—3，提交环境与模型文件检查记录、推理代码、关键运行截图、显存数据及不同精度/量化方案的对比结论。

第 2 章 提示词工程与 RAG 应用开发

学习目标：

- (1) 知识目标：理解提示词结构与常用提示技术，说明 RAG 从文档载入、切分、向量化、检索到生成的完整流程，了解 Advanced RAG 与 Agentic RAG 的优化机制。
- (2) 能力目标：能够围绕任务设计并迭代提示词，构建本地向量知识库，配置查询改写、重排序与上下文压缩，并将检索能力封装为工具完成 Agentic RAG 应用原型。
- (3) 素质目标：形成尊重知识来源、保护数据与知识产权、核验生成结果和控制工具权限的责任意识，能够审慎评价检索证据与模型回答的一致性。

课程思政安排：结合知识库建设和智能体工具调用，引导学生坚持实事求是、来源可追溯和数据合规，认识模型能力扩展与责任边界同步增长，树立技术向善的应用观。

学习内容：

- (1) 提示词结构、消息角色及零样本、少样本和思维链方法。
- (2) 提示词测试、错误分析、版本对比与迭代优化。
- (3) RAG 流程及多类型文档载入、清洗、切分和元数据管理。
- (4) Embedding、Chroma 向量数据库、相似度检索与上下文组织。
- (5) Naive、Advanced、Modular RAG 及查询改写、重排序和上下文压缩。
- (6) Agent、ReAct、Function Calling 与 LangChain 工具机制。
- (7) 知识库工具封装、Agentic RAG 构建及多场景测试。

重点和难点：提示词结构与迭代方法；RAG 完整链路、向量数据库、查询改写与重排序；知识库工具封装及 Agentic RAG 的检索决策与证据处理。

学习资源：

- (1) 课件：对应第 4—7 节的内容。

(2) 实验材料：对应实验 4—7 的相关材料。

(3) 教材：对应提示词工程、向量检索、RAG 和 Agent 应用的相关内容。

(4) 线上资源：LangChain Retrieval

(<https://docs.langchain.com/oss/python/langchain/retrieval>)；LangChain Tools

(<https://docs.langchain.com/oss/python/langchain/tools>)；LangChain Agents

(<https://docs.langchain.com/oss/python/langchain/agents>)。

(5) 在线课程：《大模型调优与部署技术》在线课程（课程号：YKmxR3），智慧树平台(<https://www.zhihuishu.com/>)。

作业要求：

完成实验 4—7，提交提示词优化对比、知识库构建记录、基础与进阶 RAG 结果、Agentic RAG 工具调用过程及基于证据的效果分析。

第 3 章 大模型监督微调与训练数据构建

学习目标：

(1) 知识目标：理解 SFT、PEFT、LoRA 与 QLoRA 的基本原理和差异，说明训练数据格式、关键训练参数、adapter 与基座模型的关系，以及 AI 数据生成在训练数据优化中的作用。

(2) 能力目标：能够构建和检查 prompt/completion 或 messages 数据，完成 SFT、LoRA 和 QLoRA 训练链路，处理 adapter 保存与合并，并利用结构化输出生成、合并和抽检训练数据。

(3) 素质目标：形成数据质量优先、训练过程可复现、生成数据需审查和模型能力需验证的工程意识，遵守数据安全、版权与学术诚信规范。

课程思政安排：通过训练数据构建与模型微调，引导学生认识高质量数据、规范实验和自主实践对技术创新的基础作用，坚持数据合规、尊重知识产权，反对以生成结果替代独立思考。

学习内容：

(1) SFT 的定位及 text、messages、prompt/completion 等训练数据格式。

(2) 数据划分、Chat Template、思考/非思考样本与训练参数管理。

(3) 基于 Transformers、TRL 和 SFTTrainer 的全参数微调流程。

(4) LoRA 的低秩适配原理、关键参数及 adapter 保存、加载与合并。

(5) QLoRA 的 4bit 基座、k-bit 训练准备、梯度检查点和显存优化。

(6) 多来源数据的转换、比例控制、合并与 Token 长度分析。

(7) 基于结构化输出生成训练数据，并进行过滤、去重、抽检和效果验证。

重点和难点：SFT、LoRA 与 QLoRA 的技术差异及适用场景；训练数据格式、关键参数和 adapter 生命周期；多来源数据质量控制与训练问题定位。

学习资源：

- (1) 课件：对应第 8—11 节的内容。
- (2) 实验材料：对应实验 8—11 的相关材料。
- (3) 教材：对应监督微调、参数高效微调、量化微调和数据构建的相关内容。
- (4) 线上资源：TRL SFTTrainer (https://huggingface.co/docs/trl/sft_trainer)；PEFT LoRA (https://huggingface.co/docs/peft/developer_guides/lora)；Datasets Quickstart (<https://huggingface.co/docs/datasets/quickstart>)；bitsandbytes 官方文档 (<https://huggingface.co/docs/bitsandbytes/index>)。
- (5) 在线课程：《大模型调优与部署技术》在线课程（课程号：YKmxR3），智慧树平台 (<https://www.zhihuishu.com/>)。

作业要求：

完成实验 8—11，提交数据格式与统计结果、训练配置、日志和 checkpoint 记录、微调前后输出对比，以及生成数据质量和数据分布对模型效果的分析。并在智慧树上按要求完成作业 1。

第 4 章 继续预训练与偏好对齐

学习目标：

- (1) 知识目标：理解继续预训练、SFT、RLHF 与 DPO 在大模型训练阶段中的不同作用，说明连续语料语言建模、偏好数据和参考模型的基本原理。
- (2) 能力目标：能够将领域文本整理为继续预训练语料，完成 token 拼接、固定长度分块与训练；能够构建 prompt/chosen/rejected 偏好数据并使用 DPOTrainer 完成偏好优化与指标分析。
- (3) 素质目标：形成以事实数据、科学实验和人类价值为依据开展模型优化的意识，关注领域语料合规、模型行为安全、公平性与能力漂移风险。

课程思政安排：结合领域知识注入与人类偏好对齐，引导学生理解技术能力必须接受安全、伦理和社会价值约束，在数据选择、反馈设计和结果评价中坚持正确价值导向。

学习内容：

- (1) 继续预训练与 SFT 的目标差异及基座模型选择。
- (2) 领域语料清洗、JSONL 整理、通用域回放与固定长度语言建模样本构造。
- (3) 全量及 4bit LoRA 继续预训练流程。
- (4) 强化学习、RLHF 的关键要素与训练流程。
- (5) DPO 的偏好优化思想及 prompt、chosen、rejected 数据处理。
- (6) 参考模型、beta、DPO 损失及全量/低显存训练指标分析。

重点和难点：继续预训练语料与语言建模样本构造；RLHF 流程与 DPO 偏好数据；知识注入、行为监督和偏好学习的差异及能力漂移、安全风险。

学习资源：

- (1) 课件：对应第 12—13 节的内容。
- (2) 实验材料：对应实验 12—13 的相关材料。
- (3) 教材：对应继续预训练、RLHF 和偏好优化的相关内容。
- (4) 线上资源：Transformers 因果语言建模指南（https://huggingface.co/docs/transformers/tasks/language_modeling）；TRL DPOTrainer（https://huggingface.co/docs/trl/dpo_trainer）。
- (5) 在线课程：《大模型调优与部署技术》在线课程（课程号：YKmxR3），智慧树平台（<https://www.zhihuishu.com/>）。

作业要求：

完成实验 12—13，提交语料处理与固定长度分块结果、继续预训练日志、偏好数据样例、DPO 训练指标及训练前后偏好表现分析。

第 5 章 大模型评估与效果分析

学习目标：

- (1) 知识目标：理解模型评估在训练—测评—分析—再优化闭环中的作用，区分人工测试、Benchmark、规则指标和 LLM-as-a-Judge 等评测方式。
- (2) 能力目标：能够使用 EvalScope 接入本地模型、API 模型和微调模型，完成标准任务及自定义选择题、问答任务评测，并根据指标和样例分析模型差异。
- (3) 素质目标：形成客观、可复现、不过度解读单一分数的科学评价意识，能够说明数据集、指标、样本规模和评审模型带来的局限。

课程思政安排：通过规范测评和结果分析，引导学生坚持实事求是、公开透明和可复现原则，反对选择性报告结果，以科学证据评价技术效果。

学习内容：

- (1) 模型评估的任务、数据集、指标、版本和报告要素。
- (2) 人工测试、Benchmark、规则指标与 LLM-as-a-Judge 的适用场景。
- (3) EvalScope 的模型适配、数据适配、任务配置与结果输出。
- (4) 本地模型、OpenAI 兼容 API 和微调模型接入。
- (5) 标准任务及自定义选择题、参考/无参考问答评测。
- (6) 准确率、ROUGE、BLEU、LLM 评审的局限及多维结果分析。

重点和难点：EvalScope 评测流程及模型、数据接入；自定义任务与多指标分析；合理选择指标并结合分数、样例和评测限制形成客观结论。

学习资源：

- (1) 课件：对应第 14 节的内容。
- (2) 实验材料：对应实验 14 的相关材料。
- (3) 教材：对应模型评估、指标设计和效果分析的相关内容。

(4) 线上资源: EvalScope 官方文档 (<https://evalscope.readthedocs.io/en/latest/>) ; EvalScope 官方项目 (<https://github.com/modelscope/evalscope>) 。

(5) 在线课程: 《大模型调优与部署技术》在线课程 (课程号: YKmxR3), 智慧树平台 (<https://www.zhihuishu.com/>) 。

作业要求:

完成实验 14, 提交模型接入、标准任务、自定义 MCQ/QA、规则指标和 LLM 评审结果, 并撰写原始模型与微调模型的综合效果分析。

第 6 章 大模型推理服务与部署

学习目标:

(1) 知识目标: 理解模型部署的服务化目标, 说明 Ollama 与 LMDeploy 的定位、接口、推理后端、量化优化和应用接入方式。

(2) 能力目标: 能够使用 Ollama 管理和调用本地模型, 使用 LMDeploy 完成离线推理、量化和 OpenAI 兼容 API 部署, 并对显存、加载耗时和生成速度进行比较。

(3) 素质目标: 形成关注系统稳定性、接口规范、资源效率、安全边界和运行可观测性的工程责任意识。

课程思政安排: 结合模型服务化部署, 引导学生遵守软件许可、接口规范和网络安全要求, 重视资源节约、服务稳定和用户数据保护, 以可靠工程服务真实需求。

学习内容:

(1) 模型训练、评估与服务化部署的关系及资源、接口要求。

(2) Ollama 安装、模型下载运行、缓存和资源管理。

(3) Ollama Python 与 OpenAI 兼容接口的非流式、流式调用。

(4) Modelfile 参数、模板与 GGUF 模型导入。

(5) LMDeploy 离线推理、TurboMind/PyTorch Engine 及关键参数。

(6) AWQ、KV Cache 量化与 OpenAI 兼容 API 服务部署。

(7) 部署服务接入测评、工具调用和 Gradio, 并比较不同部署方案。

重点和难点: Ollama 模型管理与接口调用; LMDeploy 推理后端、量化和 OpenAI 兼容服务; 权重量化与 KV Cache 量化的区别及不同后端的性能比较。

学习资源:

(1) 课件: 对应第 15—16 节的内容。

(2) 实验材料: 对应实验 15—16 的相关材料。

(3) 教材: 对应模型量化、推理优化和服务化部署的相关内容。

(4) 线上资源: Ollama 官方文档 (<https://docs.ollama.com/>) ; Ollama OpenAI 兼容接口 (<https://docs.ollama.com/api/openai-compatibility>) ; LMDeploy 官方文档 (<https://>

lmdeploy.readthedocs.io/en/latest/）。

（5）在线课程：《大模型调优与部署技术》在线课程（课程号：YKmxR3），智慧树平台（<https://www.zhihuishu.com/>）。

作业要求：

完成实验 15—16，提交服务安装与模型管理记录、SDK/API 调用结果、量化与后端对比数据、服务接入结果及部署方案总结。

第 7 章 视觉大模型应用与微调

学习目标：

（1）知识目标：理解视觉大模型的视觉编码器、跨模态连接器与大语言模型协同机制，说明多模态数据、LoRA 微调、合并、量化、部署和评估的完整流程。

（2）能力目标：能够使用 ms-swift 完成图片与视频推理，构建多模态 JSONL 数据，实施视觉大模型 LoRA 微调、adapter 推理、模型合并、量化和 vLLM 服务部署。

（3）素质目标：形成保护图像与视频隐私、尊重数据版权、核验多模态输出和控制资源消耗的责任意识，提升持续学习多模态前沿技术的能力。

课程思政安排：结合国产视觉大模型与 OCR 应用，引导学生认识多模态技术服务教育和产业的价值，同时关注肖像隐私、数据版权、生成内容安全与无障碍应用，践行负责任的人工智能。

学习内容：

（1）视觉大模型的任务特点，以及视觉编码器、连接器和语言模型结构。

（2）Qwen-VL 系列能力演进与 ms-swift 统一工具链。

（3）图片、视频及命令行多模态推理。

（4）多模态 JSONL 数据结构与公开、自定义数据集准备。

（5）视觉大模型 LoRA 微调、adapter 推理和基座模型合并。

（6）量化、vLLM OpenAI 兼容服务部署与调用。

（7）不同模型形态的效果评估、模型发布及资源影响因素。

重点和难点：视觉大模型架构与多模态数据格式；ms-swift 微调工具链、adapter 合并和 vLLM 部署；视觉 token 显存压力及微调、量化、部署环节模型兼容性。

学习资源：

（1）课件：对应第 17 节的内容。

（2）实验材料：对应实验 17 的相关材料。

（3）教材：对应视觉语言模型、多模态微调与部署的相关内容。

（4）线上资源：Qwen3-VL 官方项目（<https://github.com/QwenLM/Qwen3-VL>）；ms-swift 官方文档（<https://swift.readthedocs.io/en/latest/>）；vLLM 官方文档（<https://docs.vllm.ai/en/latest/>）。

（5）在线课程：《大模型调优与部署技术》在线课程（课程号：YKmxR3），智慧树平台（<https://www.zhihuishu.com/>）。

作业要求：

完成实验 17，提交多模态推理、数据构建、LoRA 训练、adapter 测试、模型合并/量化、API 部署与效果评估结果，并总结完整工程流程。并在智慧树上按要求完成作业 2。

四、课程实验（实践）内容及要求

（一）实验安排

实验（实践）项目名称	类型	要求	学时
实验 1：开源大模型本地部署	验证型实验	课内必做	1
实验 2：大模型原理分析	验证型实验	课内必做	1
实验 3：大模型量化部署	验证型实验	课内必做	1
实验 4：提示词工程应用实战	验证型实验	课内必做	1
实验 5：RAG 应用实战	验证型实验	课内必做	1
实验 6：RAG 进阶实战	验证型实验	课内必做	1
实验 7：Agentic RAG 应用实战	验证型实验	课内必做	1
实验 8：SFT 全量微调	验证型实验	课内必做	1
实验 9：LoRA 参数高效微调	验证型实验	课内必做	1
实验 10：QLoRA 量化微调	验证型实验	课内必做	1
实验 11：AI 数据生成实战	验证型实验	课内必做	1
实验 12：继续预训练微调	验证型实验	课内必做	1
实验 13：基于人类反馈的强化学习	验证型实验	课内必做	1

实验 14：模型评估	验证型实验	课内必做	1
实验 15：Ollama 模型部署	验证型实验	课内必做	1
实验 16：LMDeploy 模型部署	验证型实验	课内必做	1
实验 17：基于 ms-swift 的视觉大模型应用及微调实战	验证型实验	课内必做	2

（二）实践内容与要求

实验 1 开源大模型本地部署

实验目的：

- （1）配置开源大模型本地推理环境并下载模型。
- （2）使用 Transformers 的高层和底层接口完成推理。
- （3）比较两类调用方式并归纳本地部署流程。

课程思政安排：通过国产开源模型下载与本地运行，使学生认识自主可控人工智能生态的价值，形成遵守开源许可、规范配置环境和如实记录过程的工程意识。

实验内容：

- （1）创建独立环境，配置 CUDA、PyTorch、Transformers 等依赖并验证 GPU。
- （2）下载并规范管理 Qwen 开源模型文件。
- （3）分别使用 pipeline 和 AutoTokenizer、AutoModelForCausalLM 完成文本生成。
- （4）比较两类调用方式并总结本地部署流程。

实验要求：

- （1）实验分组人数：1 人；
- （2）实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- （3）实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 2 大模型原理分析

实验目的：

- （1）识别模型文件结构及主要配置作用。
- （2）应用 Tokenizer 与 Chat Template 构造模型输入。

(3) 分析底层生成、结果解析及参数影响。

课程思政安排：通过逐层分析模型输入与生成过程，培养学生尊重技术原理、基于证据解释现象和严谨排查问题的科学精神。

实验内容：

- (1) 检查模型权重、配置、分词器和生成配置文件。
- (2) 使用 Tokenizer 完成分词、编码与解码。
- (3) 用 Chat Template 组织多角色消息，并比较思考模式设置。
- (4) 运行底层推理，调整问题与生成参数并分析输出差异。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验3 大模型量化部署

实验目的：

- (1) 使用不同 dtype 和 bitsandbytes 完成模型加载。
- (2) 记录并比较 FP32、FP16、BF16、8bit、4bit 的显存与输出。
- (3) 评价量化方案的资源收益和适用条件。

课程思政安排：通过量化前后显存与效果对比，引导学生关注绿色计算和资源节约，在性能、精度与能耗之间作出负责任的工程选择。

实验内容：

- (1) 检查量化环境，建立模型加载与生成阶段的显存记录方法。
- (2) 比较 FP32、FP16、BF16 的显存占用和输出结果。
- (3) 使用 BitsAndBytesConfig 加载并测试 8bit、4bit 模型。
- (4) 综合评价各方案的显存节省、稳定性、输出质量和部署适用性。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验4 提示词工程应用实战

实验目的：

- (1) 理解提示词结构与消息角色。
- (2) 应用零样本、少样本及思维链提示方法。
- (3) 围绕任务迭代提示词并评价输出质量。

课程思政安排：通过提示词结构与输出对比，培养学生清晰表达、事实核验和审慎使用生成式人工智能的意识。

实验内容：

- (1) 检查本地模型环境并运行基础提示词。
- (2) 组合角色、背景、格式和限制条件，比较消息角色对输出的控制。
- (3) 完成零样本、少样本及思维链提示实验。
- (4) 围绕课程介绍任务迭代提示词并评价结果。

实验要求：

- (1) 实验分组人数：1人；
- (2) 实验环境要求：PC或Mac一台；16G及以上内存，Nvidia RTX 3060 12g及其以上显卡，40G硬盘空间；Windows 10/11操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验5 RAG 应用实战

实验目的：

- (1) 载入、切分文档并生成向量表示。
- (2) 使用 Chroma 构建与检索知识库。
- (3) 构建基础 RAG 问答并比较增强效果。

课程思政安排：通过知识库构建与来源检索，引导学生重视知识产权、数据合规、信息来源可信度和回答可追溯性。

实验内容：

- (1) 载入本地和网页文档，比较字符与递归切分并设置切分参数。
- (2) 使用本地 Embedding 模型生成向量并写入 Chroma。
- (3) 检索相关片段并结合本地大模型生成有依据的回答。

(4) 用多问题比较直接生成与 RAG 回答的准确性、依据性和稳定性。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 6 RAG 进阶实战

实验目的：

- (1) 优化 RAG 数据、检索和生成链路。
- (2) 应用查询改写、重排序与上下文压缩。
- (3) 构建并验证 Advanced RAG 问答流程。

课程思政安排：通过 RAG 链路分阶段优化，培养学生实事求是、持续改进和用实验数据验证优化效果的科学方法。

实验内容：

- (1) 清洗网页数据，进行章节化切分、上下文补充和元数据标注。
- (2) 配置查询 instruction 并构建优化后的 Chroma 知识库。
- (3) 完成查询改写、多片段召回、Reranker 重排序和上下文压缩。
- (4) 优化生成提示词，并用完整问答流程比较基础与 Advanced RAG。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 7 Agentic RAG 应用实战

实验目的：

- (1) 将知识库检索封装为智能体工具。
- (2) 使用系统提示词和 create_agent 构建 Agentic RAG。

(3) 分析多类问题下的工具选择与回答效果。

课程思政安排：通过智能体工具调用，强化权限边界、过程可观察和结果核验意识，认识能力扩展伴随责任增长。

实验内容：

- (1) 验证本地与云端聊天模型的调用和工具绑定能力。
- (2) 将知识库检索封装为工具，并设计直接回答、检索和证据不足规则。
- (3) 使用 `create_agent` 构建 Agentic RAG，测试基础、知识库、复合和信息不足问题。
- (4) 新增主题工具并评价工具选择、准确性、稳定性和证据处理。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 8 SFT 全量微调

实验目的：

- (1) 构建对话式微调数据并划分数据集。
- (2) 使用 `SFTConfig` 和 `SFTTrainer` 完成全量微调。
- (3) 加载 `checkpoint` 并比较微调前后行为。

课程思政安排：通过监督数据和训练日志管理，培养学生尊重数据、规范实验、独立完成训练任务和保护模型资产的职业素养。

实验内容：

- (1) 配置训练环境并加载基础模型。
- (2) 构建对话式 JSONL 数据，完成读取和训练/验证集划分。
- (3) 配置 `SFTConfig`，使用 `SFTTrainer` 训练并观察日志与 `checkpoint`。
- (4) 加载微调模型，比较身份类、普通和 `/no_think` 输入效果。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验9 LoRA 参数高效微调

实验目的：

- (1) 处理自我认知数据并配置 LoRA adapter。
- (2) 使用 SFTTrainer 完成 LoRA 训练。
- (3) 加载、合并 adapter 并评价微调效果。

课程思政安排：通过参数高效微调实践，引导学生以创新方法降低资源门槛，形成节约算力、规范复用和持续优化的工程意识。

实验内容：

- (1) 清洗 self-cognition 数据并转换为对话式训练格式。
- (2) 加载模型和数据，配置 LoRA 参数与 SFT 训练参数。
- (3) 完成 LoRA 训练、adapter 加载、合并与保存。
- (4) 用身份和通用问题比较原始/微调模型，并完成个性化训练。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验10 QLoRA 量化微调

实验目的：

- (1) 构建混合训练数据并确定合适序列长度。
- (2) 完成 4bit 模型准备、LoRA 配置与 QLoRA 训练。
- (3) 分析训练稳定性、显存收益和输出质量。

课程思政安排：通过低比特量化训练，引导学生在有限条件下合理配置资源、客观分析代价，践行绿色高效的技术应用。

实验内容：

- (1) 转换并混合日常对话与自我认知数据，调整比例并统计 Token 长度。
- (2) 以 4bit、NF4 等配置加载模型并完成 k-bit 训练准备。
- (3) 配置 LoRA、梯度检查点和 SFT 参数，完成 QLoRA 训练。

(4) 结合日志、显存与输出分析训练稳定性及 LoRA/QLoRA 差异。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 11 AI 数据生成实战

实验目的：

(1) 使用教师模型和结构化输出生成训练样本。

(2) 统一、合并并检查多来源思考/非思考数据。

(3) 重新训练并评价数据优化效果。

课程思政安排：通过教师模型生成训练数据，引导学生遵守隐私与版权规范，坚持结构校验、人工抽检和不以生成内容替代独立判断。

实验内容：

(1) 分析现有数据问题，准备带思考和非思考的日常对话、自我认知数据。

(2) 使用 Pydantic 与教师模型生成结构化思考样本并转换格式。

(3) 合并、过滤、去重、抽检并保存多来源训练数据。

(4) 基于优化数据重新 QLoRA 训练，比较身份、思考和通用问答表现。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 12 继续预训练微调

实验目的：

(1) 将领域连续文本构造为语言建模样本。

(2) 完成全量与 4bit LoRA 继续预训练。

(3) 分析领域适应效果及教学实验局限。

课程思政安排：通过领域语料处理与继续预训练，强化数据来源合规、专业知识严谨和训练结果可复现的意识。

实验内容：

- (1) 清洗领域网页语料，保存为 text 格式 JSONL。
- (2) 分词并添加结束标记，将 Token 拼接、定长分块并构造 labels。
- (3) 划分数据集并使用 Trainer 完成全量继续预训练。
- (4) 使用 4bit 与 LoRA 完成参数高效训练，比较资源与产物差异。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 13 基于人类反馈的强化学习

实验目的：

- (1) 构建并处理 DPO 偏好数据。
- (2) 完成全量及 4bit LoRA DPO 训练。
- (3) 依据训练指标和概率对比评价偏好优化效果。

课程思政安排：通过偏好数据与 DPO 训练，引导学生理解模型能力必须接受安全、伦理、公平与人类价值约束。

实验内容：

- (1) 筛选偏好数据并转换为 prompt、chosen、rejected 格式，划分训练和验证集。
- (2) 配置策略/参考模型与 DPOConfig，完成全量 DPO 训练。
- (3) 使用 4bit 与 LoRA 完成低显存 DPO 训练。
- (4) 分析 loss、reward、logps 等指标及验证集偏好概率，比较两类训练方案。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 14 模型评估

实验目的：

- (1) 使用 EvalScope 接入本地、API 和微调模型。
- (2) 完成标准及自定义选择题、问答任务评测。
- (3) 比较模型指标、样例和能力变化。

课程思政安排：通过多任务、多指标评测，培养学生实事求是、完整报告结果、关注评测局限和反对选择性结论的科学态度。

实验内容：

- (1) 配置 EvalScope，验证本地模型和 OpenAI 兼容 API 的最小评测链路。
- (2) 使用标准任务评测原始及微调模型。
- (3) 构建自定义选择题、参考答案和无参考答案问答任务。
- (4) 结合准确率、ROUGE/BLEU、LLM 评审和失败样例比较模型表现与局限。

实验要求：

- (1) 实验分组人数：1 人；
- (2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统
- (3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 15 Ollama 模型部署

实验目的：

- (1) 使用 Ollama 下载、运行和管理本地模型。
- (2) 通过 Python、OpenAI 兼容接口完成非流式与流式调用。
- (3) 完成小规模测评和 Modelfile 自定义模型。

课程思政安排：通过本地模型服务管理，培养学生遵守接口规范、保护本地数据、及时释放资源和保障运行安全的工程责任。

实验内容：

- (1) 安装并配置 Ollama，下载、运行和管理适配本机的模型。
- (2) 通过 Ollama Python 包和 OpenAI 兼容接口完成非流式、流式调用。
- (3) 将 Ollama 服务接入 EvalScope 完成小规模测评。

(4) 使用 Modelfile 设置角色和参数，创建自定义模型并体验 GGUF 导入。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 16 LMDeploy 模型部署

实验目的：

(1) 使用 LMDeploy 两类后端完成离线推理。

(2) 应用量化优化并比较显存与速度。

(3) 部署 OpenAI 兼容服务并接入测评和页面。

课程思政安排：通过推理后端与服务化部署对比，培养学生关注系统可靠性、开放标准、资源效率和可维护性的职业素养。

实验内容：

(1) 创建 LMDeploy 环境并建立显存、加载和生成耗时的观测基线。

(2) 分别使用 Transformers、TurboMind 和 PyTorch Engine 推理并比较。

(3) 完成 AWQ 权重量化与 KV Cache 量化测试。

(4) 启动 OpenAI 兼容服务，使用 SDK、EvalScope、Function Calling 和 Gradio 验证部署。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：PC 或 Mac 一台；16G 及以上内存，Nvidia RTX 3060 12g 及其以上显卡，40G 硬盘空间；Windows 10/11 操作系统

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

实验 17 基于 ms-swift 的视觉大模型应用及微调实战

实验目的：

(1) 使用 ms-swift 完成图片、视频推理及多模态数据构建。

(2) 完成视觉大模型 LoRA 微调、合并和量化。

(3) 部署、测评并发布可调用的视觉模型。

课程思政安排：通过视觉大模型训练与部署，引导学生保护图像视频隐私、尊重数据版权、核验多模态输出并关注技术的社会影响。

实验内容：

(1) 配置云端 GPU 环境，下载 Qwen3-VL 并完成图片、视频推理。

(2) 使用公开数据快速跑通 LoRA，并构建自定义 LaTeX OCR 多模态 JSONL 数据。

(3) 完成自定义数据微调、adapter 推理、模型合并与量化。

(4) 部署 vLLM 兼容服务，比较多种模型形态并发布最终模型。

实验要求：

(1) 实验分组人数：1 人；

(2) 实验环境要求：具备满足 Qwen3-VL 模型推理、LoRA 微调与 vLLM 部署需求的 GPU 云服务器，配置 Python、PyTorch、ModelScope、ms-swift、vLLM 和 EvalScope 等环境，并预留充足的数据盘空间。

(3) 实验过程、现象或数据记录等要求：参照实验手册

实验报告要求：

实验报告内容需包括：实验目的、实验设备、实验内容与要求、实验过程和实验结果。

五、课程教学方法和手段

(一) 课堂讲授

(1) 采用线上线下结合教学：课前通过课程平台发布课件、学习资料和实验准备要求，引导学生预习开源大模型、本地推理、微调方法和部署工具等内容；课中围绕关键概念、技术流程和典型案例开展讲授与演示；课后通过课程平台、学习群和实验任务巩固学习效果。

(2) 采用案例驱动教学法：结合开源大语言模型本地部署、提示词优化、RAG 知识库构建、SFT 微调、LoRA/QLoRA 微调、模型评估和量化部署等典型案例，帮助学生理解大模型调优与部署的技术链路，并引导学生分析不同方法的适用场景、优势和局限。

(3) 采用项目式与任务驱动教学法：将课程内容拆分为本地推理环境搭建、提示词设计、数据处理、知识库构建、模型微调、评估对比和部署发布等递进任务，使学生在连续任务中逐步形成大模型应用开发、调优和部署的实践能力。

(4) 在教学过程中采用多媒体与演示教学相结合的手段：通过多媒体课件、屏幕演示、代码运行演示、终端操作、电子板书和传统板书等方式讲解模型调用流程、训练参数配置、实验结果分析和部署过程，提高课堂教学信息量，增强教学的直观性和可操作性。

(5) 加强答疑与互动：建立课程学习群，开展课内讨论和课外答疑，围绕环境配置、模型

下载、数据格式、训练报错、显存占用、模型效果和部署问题进行集中解答；原则上每两周至少进行一次阶段性答疑，并结合学生实验完成情况进行针对性指导。

（二）实验（实践）教学

（1）本课程的实验教学为非独立设课，是《大模型调优与部署技术》课程中的重要实践环节，目的是培养学生运用实验方法对大模型本地推理、知识库构建、模型微调、效果评估和部署应用等复杂工程问题进行分析、设计、实现和验证的初步能力。

（2）实验教学采用任务驱动与分阶段训练相结合的方式，围绕开源大模型本地部署、提示词工程、RAG 应用、SFT 微调、LoRA/QLoRA 微调、数据生成、模型评估和量化部署等内容组织实验，使学生在连续实践中掌握大模型调优与部署的基本流程和关键操作。

（3）实验成绩主要依据实验报告的整体完成情况进行综合评价，重点考查是否按照要求完成各项实验内容，实验过程、运行结果及相关记录是否完整，以及是否对实验结果、存在问题和改进方向进行总结与反思。每次实验成绩采用百分制记分。

（4）学生进入实验室需要考勤；实验过程中应遵守实验室管理规定，规范使用计算资源、模型文件、数据集和实验平台；实验结束后，学生需按时提交实验报告，教师在批改后进行成绩登记，并作为学生实验成绩记录在案。

六、课程考核方式

本课程采用形成性评价方式，考核学生的目标达成度。

（一）考核方式和记分制

本课程考核方式为考试；考核成绩采用百分制记分。

（二）考核形式和成绩构成

考核成绩为总评成绩，由平时成绩和期末成绩二部分组成，其中平时成绩占比 50%，期末成绩占比 50%。

成绩构成	考核形式	成绩比例	考核要求（评价标准）
平时成绩	课堂表现	10%	每位学生课堂表现基础分为 8 分，满分为 10 分。学生应按时参加课堂学习，不旷课、不迟到、不早退；课堂上认真听讲，积极参与教学活动，不从事与课堂学习无关的事情；能够主动与教师、同学交流课程相关问题，并积极参与线上、线下讨论。迟到或早退一次扣 0.5 分，旷课一次扣 1 分；积极回答问题、参与课堂互动或讨论，每次加 0.5 分。课堂表现成绩根据学生实际表现进行累计加减，最高不超过 10 分，最低不低于 0 分。

	作业	20%	本课程共布置 2 次作业，每次 10 分，共 20 分。作业成绩根据完成质量和提交情况进行评定。学生应独立完成作业，发现抄袭、代写等情况，将根据情节轻重予以扣分，情节严重的当次作业记为 0 分。
	实验报告	20%	本课程共安排 17 次实验，实验成绩满分 20 分。学生应认真完成实验任务，规范操作，遵守实验室规定，并按时提交实验报告。实验成绩根据 17 次实验成绩折算计算；未按时提交实验报告的，当次实验成绩记为 0 分。发现抄袭、代写等情况，将根据情节轻重予以扣分，情节严重的当次实验成绩记为 0 分。
期末成绩	期末考试	50%	闭卷笔试。试卷包括选择题、判断题、填空题、简答题、综合题五种题型。要求不死记硬背，灵活运用课程知识，在理解的基础上答题。
总评成绩		100%	总评成绩=平时成绩+期末成绩

（三）课程目标达成度评价方式

本课程目标达成度采用考核成绩分析法。对 3 个课程目标进行评价，数据来源于各考核形式的考核成绩。

（1）各考核形式与课程目标的支撑关系

课程目标	考核形式
目标 1	作业中的作业 1（10 分）和期末考试中的选择题、判断题与填空题（25 分）进行评价。
目标 2	通过作业中的作业 2（10 分）、学生提交的第 1、2、4-10、12、15-17 次实验报告（15 分），以及期末考试中的综合题（15 分）进行评价。
目标 3	通过课堂表现（10 分），学生提交的第 3、11、13、14 次实验报告（5 分），以及期末考试中的简答题（10 分）进行评价。

（2）计算方法

首先针对每条课程目标，按其所支撑的考核形式的考核成绩计算分目标达成度，计算公式为：

$$\text{某课程目标达成度} = \frac{1}{n} \sum_{i=1}^n \frac{\text{支撑该目标的考核形式 } i \text{ 的平均分}}{\text{支撑该目标的考核形式 } i \text{ 的总分}}$$

课程教学目标达成度为各课程目标达成度的最小值。

七、学习资源

（一）推荐教材

程戈.《大模型垂直领域低算力迁移：微调、部署与优化》.机械工业出版社,2024年12月,ISBN:978-7-111-76767-1.

（二）参考书目

(1) 庄建、腾海云、庄金兰.《大模型实战：微调、优化与私有化部署》.电子工业出版社,2024年12月,ISBN:978-7-121-49323-2.

(2) 王晓华.《ChatGLM3 大模型本地化部署、应用开发与微调》.清华大学出版社,2024年4月,ISBN:978-7-302-65881-8.

(3) 程戈.《ChatGPT 原理与架构：大模型的预训练、迁移和中间件编程》.机械工业出版社,2023年12月,ISBN:978-7-111-73956-2.

（三）其他参考资源

(1)《大模型调优与部署技术》在线课程(课程号:YKmxR3),智慧树平台 <https://www.zhihuishu.com/>

(2)《大模型调优与部署技术》课程课件、实验手册、代码文件与拓展材料。

(3) DeepLearning.AI Finetuning Large Language Models Course,网址:
<https://www.deeplearning.ai/courses/finetuning-large-language-models>。

(4) Hugging Face LLM Course,网址: <https://huggingface.co/learn/llm-course/chapter1/1>。

(5) Hugging Face smol-course,网址: <https://huggingface.co/learn/smol-course/unit0/1>。

(6) Transformers 官方文档,网址: <https://huggingface.co/docs/transformers/index>。

(7) TRL 官方文档,网址: <https://huggingface.co/docs/trl/index>。

(8) PEFT 官方文档,网址: <https://huggingface.co/docs/peft/index>。

(9) Qwen3-VL 官方项目,网址: <https://github.com/QwenLM/Qwen3-VL>。

(10) vLLM 官方文档,网址: <https://docs.vllm.ai/en/latest/>。

八、其他说明

本教学大纲按照 2025 级数据科学与大数据技术(专升本)专业人才培养方案制定。

制订人:



审定人:



批准人:

