

《大模型调优与部署技术》课程考核大纲

课程代码: SK3020

学 分: 2

学 时: 36 (理论学时: 18, 实践学时: 18)

考核方式: 考试

一、考核对象

数据科学与大数据技术（专升本）、数据科学与大数据技术、人工智能专业的本科学生以及选修本课程的学生。

二、考核内容与要求

第1章 开源大模型运行原理与量化部署

考核内容:

(1) 开源大模型本地运行所需的硬件、显卡驱动、CUDA、Python 或 Conda 环境、推理框架与模型文件及其依赖关系。

(2) 模型权重、config、tokenizer、generation_config 等文件，以及本地模型路径与模型仓库标识的组织 and 作用。

(3) Tokenizer 的编码与解码流程，Chat Template 对 system、user、assistant 角色和多轮消息的组织作用。

(4) 因果语言模型的自回归生成过程，以及 max_new_tokens、temperature、top_k、top_p 等生成参数。

(5) 基于 Transformers 完成模型和 Tokenizer 加载、输入构造、生成与结果解码的基本流程。

(6) FP32、FP16 与 BF16 的表示特点，以及不同精度对显存、速度和数值稳定性的影响。

(7) 8bit、4bit 等低比特量化的作用、常用配置、质量损失与硬件及推理框架兼容性。

(8) 小显存本地推理中的模型规模、精度或量化、上下文长度、生成长度、batch、并发与显存释放策略。

(9) 模型目录不完整、Tokenizer 文件缺失、路径错误、环境或设备不匹配、显存不足等常见加载与推理故障。

考核要求:

(1) 能够说明本地运行环境与模型文件之间的关系，并检查硬件、驱动、CUDA、Python 环境和依赖是否满足要求。

(2) 能够说明常见模型文件的用途，根据目录结构或报错判断路径、配置、权重及 Tokenizer 文件是否完整。

(3) 能够解释 Tokenizer 和 Chat Template 的作用，并正确组织单轮或多轮对话中的角色与消息。

(4) 能够解释常用生成参数的作用，并根据稳定复现、开放生成或长度控制等需求选择合理设置。

(5) 能够阅读或补全基础 Transformers 推理代码，正确完成加载、输入构造、生成和解码。

(6) 能够比较 FP32、FP16 与 BF16 在显存、速度和稳定性方面的差异，并说明精度选择依据。

(7) 能够说明低比特量化降低资源占用的原理，并分析量化不一定在所有硬件和框架上更快的原因。

(8) 能够针对小显存场景提出模型、精度、上下文、batch、并发和显存占用方面的组合优化方案。

(9) 能够根据错误信息和运行现象定位常见加载或推理故障，并提出有依据的排查与修复措施。

第2章 提示词工程与 RAG 应用开发

考核内容：

(1) 提示词中的角色设定、任务说明、背景信息、输出格式和限制条件，以及 system、user、assistant 消息角色。

(2) 零样本、少样本、任务分解和思维链等提示方法，以及提示词测试、错误分析与迭代优化。

(3) 提示词工程、RAG 与微调在行为控制、外部知识增强和稳定任务适配方面的适用边界。

(4) RAG 通过外部知识缓解知识过时与幻觉问题的原理，以及文档处理、检索、增强和生成的基本链路。

(5) 网页、PDF 等资料的加载与清洗，以及导航栏、页脚、重复内容和无关噪声的处理。

(6) 递归文本切分、chunk_size、chunk_overlap、章节条款边界与元数据标注对检索效果的影响。

(7) Embedding 模型、语义向量、Chroma 向量数据库、相似度检索及基础知识库构建代码。

(8) 查询向量化、候选片段召回、检索上下文组织、回答边界控制与证据一致性检查。

(9) 查询改写或扩展、分类路由、混合检索、Reranker 重排序、上下文压缩与多片段融合等进阶 RAG 方法。

(10) Agentic RAG 中的任务规划、工具选择、结果观察、继续检索与停止决策，以及外部

工具调用。

考核要求：

- (1) 能够按任务要求组织提示词要素，正确使用 system、user、assistant 角色约束模型身份、输入和输出。
- (2) 能够根据任务复杂度选择常用提示方法，并通过对比输出、分析错误和修改提示词形成迭代方案。
- (3) 能够比较提示词工程、RAG 与微调的适用问题，并为具体应用场景选择合理技术路线。
- (4) 能够解释 RAG 缓解知识过时和幻觉的条件与局限，并准确描述文档处理到增强生成的完整流程。
- (5) 能够选择合适的资料加载与清洗方法，识别并处理影响知识库质量的网页或文档噪声。
- (6) 能够根据文档结构设置切分长度与重叠，并分析片段过小、过大或缺少元数据导致的问题。
- (7) 能够阅读或补全 WebBaseLoader、RecursiveCharacterTextSplitter、Embedding 和 Chroma 知识库构建代码。
- (8) 能够完成查询检索与增强生成，判断召回内容是否真正支持回答并控制无证据生成。
- (9) 能够针对召回不足或表面相关问题，从检索前、检索中和检索后提出组合优化方案。
- (10) 能够说明 Agentic RAG 的规划和工具调用逻辑，并分析多步检索、外部系统接入及权限控制问题。

第3章 大模型监督微调与训练数据构建

考核内容：

- (1) SFT 中监督信号的含义、典型数据形态与适用场景，以及 SFT 与提示词工程、RAG 和继续预训练的区别。
- (2) text、messages、prompt 或 completion 等数据格式，Chat Template、角色字段、训练集与验证集划分。
- (3) 身份认知、基础问答、思考与非思考、长短回答等样本的比例、覆盖范围和能力保留设计。
- (4) 教师模型生成数据、多来源数据合并，以及错误、无关、重复、模板化样本的清洗、去重与人工抽检。
- (5) 全参数微调、LoRA 与 QLoRA 在参数更新范围、显存开销、训练成本和适用条件方面的差异。
- (6) LoRA 的低秩适配思想，以及 TaskType、r、lora_alpha、lora_dropout、target_modules 和 adapter 管理。
- (7) 基于 Transformers、PEFT、TRL、SFTConfig 和 SFTTrainer 的数据加载、模型配置与训练代码。

(8) 学习率、batch size、梯度累积、最大序列长度、训练轮数、日志、验证集和 checkpoint 等训练配置。

(9) 训练 loss 快速下降、固定模板输出、过拟合和通用能力退化的成因，以及数据、参数和评估改进方法。

(10) QLoRA 的 4bit 基座模型、NF4 或 FP4、二次量化、计算精度、k-bit 训练准备和分页优化器等机制。

考核要求：

(1) 能够解释 SFT 的监督来源，区分 SFT 与提示词工程、RAG、继续预训练，并判断具体任务是否适合微调。

(2) 能够构建和检查常用 SFT 数据格式，正确处理 Chat Template、角色字段及训练集和验证集划分。

(3) 能够设计兼顾目标能力与基础能力的数据配比，避免单一身份、模式或回答长度造成行为割裂。

(4) 能够识别错误、无关、重复和模板化数据的风险，并设计生成、清洗、去重和人工抽检流程。

(5) 能够比较全参数微调、LoRA 与 QLoRA 的资源代价和适用条件，为给定显存与任务选择方案。

(6) 能够解释 LoRA 核心参数的作用，合理配置注入模块，并完成 adapter 的保存、加载或合并。

(7) 能够阅读或补全基于 Transformers、PEFT 和 TRL 的 SFT 或 LoRA 训练代码，完成基础训练流程。

(8) 能够分析关键训练参数对显存、等效 batch、收敛和泛化的影响，并据此调整训练配置。

(9) 能够根据 loss 和测试表现判断过拟合或能力退化，从数据、训练强度、LoRA 参数、验证与 checkpoint 选择方面改进。

(10) 能够阅读或补全 QLoRA 配置代码，并说明 4bit 量化、NF4 或 FP4、二次量化、k-bit 训练准备和分页优化器的作用。

第4章 继续预训练与偏好对齐

考核内容：

(1) 继续预训练与 SFT 的目标和数据形态差异，以及 Base Model 与 Instruct Model 的选择和助手能力退化风险。

(2) 领域连续文本的获取、清洗、去重、合理切分、text 格式整理和通用域语料回放。

(3) 领域语料的 Tokenizer 分词、eos_token 添加、token 拼接、固定长度分块与 labels 构造。

- (4) 基于 Trainer 或 LoRA 开展继续预训练的流程、训练配置、日志监控与模型产物管理。
- (5) RLHF 的偏好数据收集、奖励模型训练和策略优化流程，以及奖励模型的作用。
- (6) DPO 中同一 prompt 下 chosen 与 rejected 偏好对、直接偏好优化目标及其与传统 RLHF 的关系。
- (7) DPO 参考模型和 beta 参数对模型偏移、偏好强度及能力保持的影响。
- (8) 偏好数据质量、DPO 训练流程、reward accuracy 或 margin 等指标，以及能力漂移、公平性和安全风险。

考核要求：

- (1) 能够比较继续预训练与 SFT 的目标和数据形态，说明模型起点选择不当可能造成的助手行为退化。
- (2) 能够构建合规的领域连续文本语料，识别噪声、重复和领域偏置，并说明通用域回放的目的。
- (3) 能够说明或完成连续语料从分词、结束标记、拼接到固定长度训练样本和 labels 的处理。
- (4) 能够配置基础继续预训练流程，根据日志判断收敛与能力保持情况，并管理训练产物。
- (5) 能够准确描述 RLHF 的主要步骤，解释奖励模型如何对回答质量提供反馈。
- (6) 能够构建和检查 chosen 或 rejected 偏好对，解释 DPO 如何提高同一 prompt 下优选回答的概率。
- (7) 能够解释参考模型和 beta 的作用，分析约束过强或过弱对偏好学习和模型漂移的影响。
- (8) 能够根据偏好数据和训练指标评价 DPO 效果，并识别偏好偏置、能力退化、公平性与安全问题。

第 5 章 大模型评估与效果分析

考核内容：

- (1) 模型评估的必要性，以及训练 loss、训练集拟合、测试集表现和真实场景泛化之间的关系。
- (2) 人工对话测试、标准 Benchmark、自定义测试集、规则指标、自动化评测和 LLM-as-a-Judge。
- (3) 准确率、Exact Match、ROUGE、BLEU 等指标的含义、适用条件与局限。
- (4) 真实场景测试集的覆盖、难度和分布设计，以及训练集隔离、样本质量与版本一致性。
- (5) 原始模型与微调模型的定量结果、典型样例、失败案例、能力退化和错误类型对比。
- (6) 延迟、首 Token 时间、吞吐量、显存占用等部署性能指标及其测量口径。
- (7) EvalScope 中本地模型、OpenAI 兼容 API 模型、标准数据集和自定义数据集的接入与执行流程。
- (8) 评测报告中的模型版本、参数、环境、数据、指标、误差分析、可复现性及评审偏差。

考核要求：

- (1) 能够说明训练完成后仍需评估的原因，并根据 loss 和测试表现判断过拟合、泛化不足或能力退化。
- (2) 能够根据任务特点组合选择人工、Benchmark、自定义测试、规则指标、自动评测或 LLM 评审方法。
- (3) 能够解释常用质量指标并识别单一指标、样本规模、答案多样性和评审模型带来的局限。
- (4) 能够构建贴近业务的测试集，控制数据泄漏和版本差异，并覆盖典型、边界及失败场景。
- (5) 能够对比训练前后模型的指标与样例，定位幻觉、格式不稳、固定模板和基础能力退化等问题。
- (6) 能够区分延迟、首 Token 时间、吞吐量和显存等指标，并为推理服务选择合适的性能评价口径。
- (7) 能够使用 EvalScope 接入本地或 API 模型与标准或自定义数据，完成基础评测和结果导出。
- (8) 能够形成包含版本、参数、环境、数据、结果和误差分析的可复现报告，并说明评审偏差与结论边界。

第 6 章 大模型推理服务与部署

考核内容：

- (1) 一次性脚本推理与稳定服务化部署的区别，以及 OpenAI 兼容接口、模型服务名和应用接入关系。
- (2) Ollama 的模型下载、运行、进程管理、Modelfile 定制与 OpenAI 兼容接口调用。
- (3) LMDeploy 的 api_server 启动命令，以及模型路径、backend、server-name、server-port、dtype、session-len、cache 和 model-name 参数。
- (4) TurboMind 与 PyTorch Engine 在模型兼容性、显存占用、性能和适用场景方面的差异。
- (5) OpenAI 客户端中的 base_url、api_key、model、messages 和生成参数，以及服务名与原始模型仓库名的区别。
- (6) KV Cache、cache-max-entry-count、session-len、batch 和并发对显存、延迟与吞吐量的影响。
- (7) 服务启动或运行中的 CUDA Out of Memory、端口或网络、模型名、接口格式和依赖兼容问题。
- (8) 推理后端、模型规模、精度或量化、上下文与生成长度、缓存、batch 和并发等性能优化手段。
- (9) 权重量化与 KV Cache 量化的作用差异，以及模型效果、资源开销、接口安全、隐私和

稳定性评估。

考核要求：

(1) 能够说明服务化部署的目标，区分实际加载模型与对外服务名，并解释客户端、接口和服务端的关系。

(2) 能够使用 Ollama 完成基础模型管理与接口调用，说明常用命令和 Modelfile 关键指令的作用。

(3) 能够阅读或补全 LMDeploy 启动命令，正确配置模型、后端、监听地址、端口、精度、上下文、缓存和服务名。

(4) 能够比较 TurboMind 与 PyTorch Engine，并根据模型支持、显存和性能要求选择推理后端。

(5) 能够阅读或补全 OpenAI 兼容客户端代码，正确设置访问地址、模型服务名、消息和生成参数。

(6) 能够解释缓存、上下文、batch 和并发参数的资源与性能权衡，并根据服务目标进行配置。

(7) 能够分析 OOM 及接口调用失败的原因，从释放显存、减小模型或上下文、调整缓存与并发、检查地址和模型名等方面排障。

(8) 能够针对速度或吞吐量目标，从后端、精度、量化、长度、缓存、batch 和并发方面提出组合优化方案。

(9) 能够区分权重量化与 KV Cache 量化，综合模型效果、显存、延迟、吞吐量、安全和隐私评价部署方案。

第 7 章 视觉大模型应用与微调

考核内容：

(1) 视觉大模型与文本大模型、传统图像分类模型在输入、输出、任务形式和开放式生成能力方面的区别。

(2) 视觉编码器、跨模态连接器、大语言模型，以及视觉 token 与文本 token 进入统一推理上下文的机制。

(3) OpenAI 兼容多模态消息中的 user、text、image_url 和图像地址，以及视觉模型服务部署与调用。

(4) 图片分辨率、视频帧数、视觉 token、上下文长度与显存占用、推理速度和信息完整性的权衡。

(5) 基于 Qwen-VL 或 ms-swift 完成图片、文档和视频推理的基本流程。

(6) 多模态 JSONL 数据中的图像路径、视觉占位符、用户指令、assistant 答案及数据质量检查。

(7) 视觉大模型 LoRA 微调、adapter 推理、模型合并、量化和 OpenAI 兼容服务部署。

（8）视觉模型原始版、微调版、合并版或量化版的效果与资源评估，以及图像视频隐私、版权和输出安全。

考核要求：

（1）能够比较视觉大模型、文本大模型与传统视觉模型，判断分类任务和开放式图文问答的适用方式。

（2）能够说明视觉信息如何编码并与文本指令联合输入语言模型，识别“仅依赖 OCR”等片面理解。

（3）能够阅读或补全视觉模型的服务端与客户端代码，正确组织文本和 image_url 多模态消息。

（4）能够分析帧数、分辨率、视觉 token 和上下文对显存与速度的影响，并提出资源受限优化方案。

（5）能够使用 Qwen-VL 或 ms-swift 完成图片、文档或视频基础推理，并根据任务选择输入方式。

（6）能够构建和检查多模态训练数据，保证图像、指令与答案对应并过滤低质量或失配样本。

（7）能够说明视觉 LoRA 微调到 adapter 推理、合并、量化和服务部署的流程及兼容性问题。

（8）能够比较不同模型形态的效果和资源开销，并识别图像视频隐私、数据版权、输出安全与算力风险。

三、考核形式与成绩构成

（一）考核成绩构成

总评成绩由平时成绩和期末成绩组成，其中平时成绩占比 50%，期末成绩占比 50%。平时考核和期末考核采用百分制，总评成绩采用百分制记分。

成绩构成	考核形式	成绩比例	考核要求
平时成绩	课堂表现	10%	每位学生课堂表现基础分为 8 分，满分为 10 分。学生应按时参加课堂学习，不旷课、不迟到、不早退；课堂上认真听讲，积极参与教学活动，不从事与课堂学习无关的事情；能够主动与教师、同学交流课程相关问题，并积极参与线上、线下讨论。迟到或早退一次扣 0.5 分，旷课一次扣 1 分；积极回答问题、参与课堂互动或讨论，每次加 0.5 分。课堂表现成绩根据学生实际表现进行累计加减，最高不超过 10 分，最低不低于 0 分。
	作业	20%	本课程共布置 2 次作业，每次 10 分，共 20 分。作业成绩根据完成质量和提交情况进行评定。学生应独立完成作

			业，发现抄袭、代写等情况，将根据情节轻重予以扣分，情节严重的当次作业记为0分。
	实验报告	20%	本课程共安排17次实验，实验成绩满分20分。学生应认真完成实验任务，规范操作，遵守实验室规定，并按时提交实验报告。实验成绩根据17次实验成绩折算计算；未按时提交实验报告的，当次实验成绩记为0分。发现抄袭、代写等情况，将根据情节轻重予以扣分，情节严重的当次实验成绩记为0分。
期末成绩	期末考试	50%	闭卷笔试。试卷包括选择题、判断题、填空题、简答题、综合题五种题型。要求不死记硬背，灵活运用课程知识，在理解的基础上答题。
总评成绩		100%	总评成绩=平时成绩+期末成绩

（二）考核形式及计分方法

1. 课堂表现

课堂表现成绩满分为10分，占课程总评成绩的10%。每位学生基础分为8分，根据考勤、课堂纪律和课堂参与情况进行累计加减。迟到或早退一次扣0.5分，旷课一次扣1分；积极回答问题、参与课堂互动或课程讨论，每次加0.5分。课堂表现成绩最高不超过10分，最低不低于0分。

2. 作业

本课程共布置2次作业，每次作业满分10分，共20分。作业成绩根据任务完成情况、内容正确性、分析过程、提交规范和提交时间进行评定。学生应独立完成作业，并在规定时间内提交。发现抄袭、代写等情况，根据情节轻重予以扣分，情节严重的当次作业成绩记为0分。两次作业成绩相加作为最终作业成绩。

3. 实验报告

本课程共安排17个实验项目，共18实验学时，其中实验1—16各1学时，实验17为2学时。实验报告考核满分20分，占课程总评成绩的20%。每个实验项目采用百分制，评分证据包括可运行代码、模型与数据配置、训练或部署日志、checkpoint或接口调用记录、性能指标、关键截图以及实验报告。

评分维度为包括以下方面：

（1）任务完成与结果有效性40分，考查规定任务是否完成、模型或服务是否正常运行、结果是否有效；

（2）过程规范与可复现性30分，考查环境、数据、参数、日志和部署配置是否记录完整并可复现；

（3）报告完整性与证据质量 20 分，考查目的、步骤、核心代码、运行证据和结果呈现是否完整清晰；

（4）对比分析与优化 10 分，考查能否基于指标比较微调、量化或部署方案，分析质量、效率和资源占用并提出改进。

各维度按“完整有效且可复现、基本完整且仅有少量缺陷、完成主要任务但证据或分析不足、基本完成但缺陷明显、未完成或结果不可验证”五档赋分，分别对应 90—100 分、80—89 分、70—79 分、60—69 分和 60 分以下。

实验报告考核成绩=[实验 1—16 原始成绩之和+2×实验 17 原始成绩]÷18×20%，折算后满分 20 分。无正当理由未提交或逾期未交的，当次实验记 0 分；经批准延期的，按任课教师公布的补交时限处理。抄袭、代写、伪造代码、日志、指标或实验结果的，经核实当次实验记 0 分；情节严重的，按学校有关规定处理。

4. 期末考试

（1）考试形式和时间

闭卷笔试，试卷满分 100 分；考试时间为 90 分钟。

（2）试题类型及比例

选择题，所占总分比例为 20%。

判断题，所占总分比例为 20%。

填空题，所占总分比例为 10%。

简答题，所占总分比例为 20%。

综合题，所占总分比例为 30%。

（3）命题权重

考核内容	命题权重
第 1 章 开源大模型运行原理与量化部署	5%
第 2 章 提示词工程与 RAG 应用开发	25%
第 3 章 大模型监督微调与训练数据构建	35%
第 4 章 继续预训练与偏好对齐	5%
第 5 章 大模型评估与效果分析	10%
第 6 章 大模型推理服务与部署	15%
第 7 章 视觉大模型应用与微调	5%
总计	100%

四、学习资源

（一）参考书目

(1) 程戈.《大模型垂直领域低算力迁移：微调、部署与优化》.机械工业出版社,2024年12月,ISBN:978-7-111-76767-1.

(2) 庄建、腾海云、庄金兰.《大模型实战：微调、优化与私有化部署》.电子工业出版社,2024年12月,ISBN:978-7-121-49323-2.

(3) 王晓华.《ChatGLM3 大模型本地化部署、应用开发与微调》.清华大学出版社,2024年4月,ISBN:978-7-302-65881-8.

(4) 程戈.《ChatGPT 原理与架构：大模型的预训练、迁移和中间件编程》.机械工业出版社,2023年12月,ISBN:978-7-111-73956-2.

(二) 其他参考资源

(1) 《大模型调优与部署技术》在线课程(课程号:YKmxR3),智慧树平台<https://www.zhihuishu.com/>

(2) 《大模型调优与部署技术》课程课件、实验手册、代码文件与拓展材料。

(3) DeepLearning.AI Finetuning Large Language Models Course, 网址:
<https://www.deeplearning.ai/courses/finetuning-large-language-models>。

(4) Hugging Face LLM Course, 网址: <https://huggingface.co/learn/llm-course>。

(5) Hugging Face smol-course, 网址: <https://huggingface.co/learn/smol-course>。

(6) Transformers 官方文档, 网址: <https://huggingface.co/docs/transformers/index>。

(7) TRL 官方文档, 网址: <https://huggingface.co/docs/trl/index>。

(8) PEFT 官方文档, 网址: <https://huggingface.co/docs/peft/index>。

(9) Qwen3-VL 官方项目, 网址: <https://github.com/QwenLM/Qwen3-VL>。

(10) vLLM 官方文档, 网址: <https://docs.vllm.ai/en/latest/>。

五、其他说明

本考核大纲依据 2025 级数据科学与大数据技术(专升本)专业的《大模型调优与部署技术》课程教学大纲制定。

制订人:

审定人:

批准人:

附：试卷样题（各题型给出一个样例即可）

选择题：

RAG 中 Embedding 模型的核心作用是（ ）。

- A. 将文本转换为语义向量，便于相似度检索
- B. 将长文档自动切分为多个片段
- C. 对候选片段进行重排序
- D. 直接生成问题的最终回答

判断题：

LoRA 中的 r 增大时，可训练参数通常增加，模型表达能力和训练成本也可能相应提高。（ ）

填空题：

LMDeploy 可以将模型封装成与_____风格兼容的接口服务，方便其他程序调用。

简答题：

简述基于向量数据库的 RAG 基本工作流程。

综合题：

某学校拟将在线学生手册构建为 Chroma 向量知识库。请完成以下任务：（1）说明从网页加载、文本切分、Embedding、向量库构建到检索的关键步骤；（2）若检索结果只与问题表面相关，请从切分策略、查询改写和 Reranker 等方面提出优化方案。